

Mobilnost turista i poslovanje hrvatskog turističkog sektora - SAPientiSat

15.1.2023

1.pitanje:

Analizirajte podatke o dnevnom prometu preko graničnih prijelaza. Postoje li razlike među vrstama graničnih prijelaza? Postoje li razlike među različitim danima u tjednu ili mjesecima?



Učitavamo podatke o domaćim i stranim ulascima i izlascima iz RH. Prijelazi se dijele na cestovni, željeznički, riječni, pomorski i zračni.

##Tablice podataka

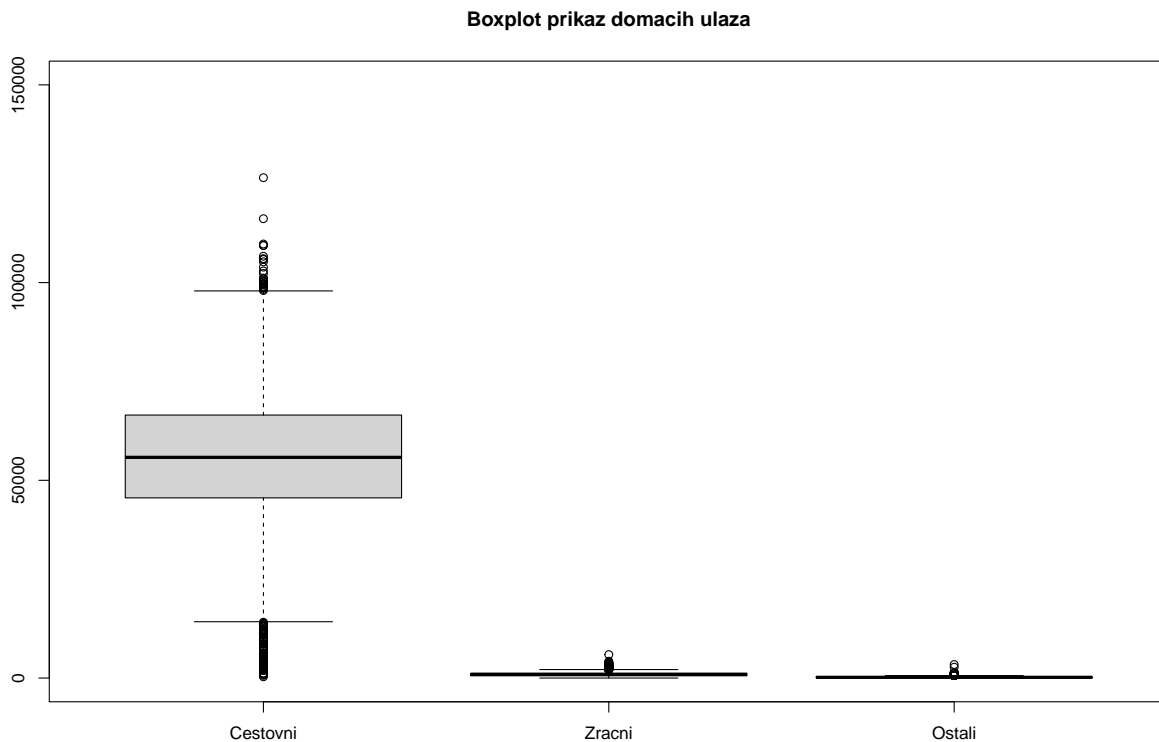
```
domaci_ul_put <- read.csv("domaci_promet/domaci_ulaz_putnici.csv")
domaci_iz_put <- read.csv("domaci_promet/domaci_izlaz_putnici.csv")
strani_ul_put <- read.csv("strani_promet/strani_ulaz_putnici.csv")
strani_iz_put <- read.csv("strani_promet/strani_izlaz_putnici.csv")
```

Grafovi


S Obzirom na to da su auto i autobus često najpraktičnija prijevozna sredstva, očekujemo veliku razliku između cestovnih prijelaza i ostalih. Napraviti ćemo graf prelazaka granice po zasebnim prijelazima. Također očekujemo vidjeti znatan pad u broju prijelaza početkom COVID-19 krize odnosno u periodu 2020-2021 godine.




Iz grafa vidimo da su naša očekivanja bila točna. Broj kretanja kroz cestovne prijelaze je znatno veći od broja kretanja kroz ostale vrste prijelaza. Ipak, treba primjetiti nešto značajniji broj korištenja necestovnih prijelaza kod stranaca u odnosu na domaće stanovnike. Iz grafa je također jasno vidljiv predviđeni pad broja prijelaza u vrijeme korone. Zbog malog broja prelazaka kroz riječne, pomorske i željezničke prijelaze u sljedećem ćemo ih prikazu grupirati u jednu skupinu nazvanu “Ostali”.




Boxplot prikaz domacih izlaza




Boxplot prikaz stranih ulaza




Boxplot prikaz stranih izlaza




Razlika ulazak/izlazak



Razlika ulazak/izlazak 2013



Razlika ulazak/izlazak period 1.1.2019–15.6.2021



Domaci ulaz

```
domaci_ulaz_prometna_sredstva <- read.csv("domaci_promet/domaci_ulaz_prometna_sredstva.csv")

names(domaci_ulaz_prometna_sredstva)

## [1] "X"                "osobni.automobili" "vlakovi"
## [4] "teretna.vozila"   "autobusi"          "plovila"
## [7] "zrakoplovi"      "UKUPNO"

attach(domaci_ulaz_prometna_sredstva)

datumi_ulaz <- as.Date(domaci_ulaz_prometna_sredstva$X, format = "%Y-%m-%d")

ukupno_ulaz <- domaci_ulaz_prometna_sredstva$UKUPNO
ukupno_ulaz[ukupno_ulaz > 100000] <- 19000

data_ulaz <- data.frame(datumi = datumi_ulaz, vrijednosti = ukupno_ulaz)
data_ulaz <- data_ulaz[order(data_ulaz$datumi), ]


data_ulaz_new <- data_ulaz
data_ulaz_new$year <- strptime(data_ulaz_new$datumi, "%Y")
data_ulaz_new$month <- strptime(data_ulaz_new$datumi, "%m")
data_ulaz_new$dan <- c("01")

data_aggr_ulaz <- aggregate(vrijednosti ~ month + year + dan, data_ulaz_new, FUN = sum)

my_cols_ulaz <- c("month", "year", "dan")
data_aggr_ulaz$month_year_ulaz <- do.call(paste, c(data_aggr_ulaz[my_cols_ulaz], sep="-"))
data_aggr_ulaz <- data_aggr_ulaz[, ! colnames(data_aggr_ulaz) %in% my_cols_ulaz]

novi_datumi_ulaz <- as.Date(data_aggr_ulaz$month_year_ulaz, format = "%m-%Y-%d")
data_aggr_ulaz$month_year_ulaz <- novi_datumi_ulaz

ggplot(data_aggr_ulaz, aes(x = month_year_ulaz, y = vrijednosti)) +
  geom_line() +
  scale_x_date(date_labels = "%Y-%m") +
  scale_y_continuous(limits = c(0, 1100000))
```



```
## Domaci izlaz
```

```
domaci_izlaz_prometna_sredstva <- read.csv("domaci_promet/domaci_izlaz_prometna_sredstva.csv")
```

```
names(domaci_izlaz_prometna_sredstva)
```

```
## [1] "X"                "osobni.automobili" "vlakovi"
## [4] "teretna.vozila"   "autobusi"          "plovila"
## [7] "zrakoplovi"      "UKUPNO"
```

```
attach(domaci_izlaz_prometna_sredstva)
```

```
datumi_izlaz <- as.Date(domaci_izlaz_prometna_sredstva$X, format = "%d/%m/%Y")
```

```
ukupno_izlaz <- domaci_izlaz_prometna_sredstva$UKUPNO
```

```
ukupno_izlaz[ukupno_izlaz > 100000] <- 19000
```

```
data_izlaz <- data.frame(datumi = datumi_izlaz, vrijednosti = ukupno_izlaz)
```

```
data_izlaz <- data_izlaz[order(data_izlaz$datumi), ]
```

```
data_izlaz_new <- data_izlaz
```

```
data_izlaz_new$year <- strftime(data_izlaz_new$datumi, "%Y")
```

```
data_izlaz_new$month <- strftime(data_izlaz_new$datumi, "%m")
```

```
data_izlaz_new$dan <- c("01")
```

```
data_aggr_izlaz <- aggregate(vrijednosti ~ month + year + dan, data_izlaz_new, FUN = sum)
```




```

my_cols_izlaz <- c("month", "year", "dan")
data_aggr_izlaz$month_year_izlaz <- do.call(paste, c(data_aggr_izlaz[my_cols_izlaz], sep="-"))
data_aggr_izlaz <- data_aggr_izlaz[, ! colnames(data_aggr_izlaz) %in% my_cols_izlaz]

novi_datumi_izlaz <- as.Date(data_aggr_izlaz$month_year_izlaz, format = "%m-%Y-%d")
data_aggr_izlaz$month_year_izlaz <- novi_datumi_izlaz

ggplot(data_aggr_izlaz, aes(x = month_year_izlaz, y = vrijednosti)) +
  geom_line() +
  scale_x_date(date_labels = "%Y-%m") +
  scale_y_continuous(limits = c(0, 1100000))

```



Strani ulaz

```

strani_ulaz_prometna_sredstva <- read.csv("strani_promet/strani_ulaz_prometna_sredstva.csv")

names(strani_ulaz_prometna_sredstva)

## [1] "X"                "osobni.automobili" "vlakovi"
## [4] "teretna.vozila"   "autobusi"          "plovila"
## [7] "zrakoplovi"      "UKUPNO"

attach(strani_ulaz_prometna_sredstva)

datumi_strani_ulaz <- as.Date(strani_ulaz_prometna_sredstva$X, format = "%Y-%m-%d")

```

```

ukupno_strani_ulaz <- strani_ulaz_prometna_sredstva$UKUPNO
ukupno_strani_ulaz[ukupno_strani_ulaz > 170000] <- 38000

data_strani_ulaz <- data.frame(datumi = datumi_strani_ulaz, vrijednosti = ukupno_strani_ulaz)
data_strani_ulaz <- data_strani_ulaz[order(data_strani_ulaz$datumi), ]

data_strani_ulaz_new <- data_strani_ulaz
data_strani_ulaz_new$year <- strftime(data_strani_ulaz_new$datumi, "%Y")
data_strani_ulaz_new$month <- strftime(data_strani_ulaz_new$datumi, "%m")
data_strani_ulaz_new$dan <- c("01")


data_aggr_strani_ulaz <- aggregate(vrijednosti ~ month + year + dan, data_strani_ulaz_new, FUN = sum)

my_cols_strani_ulaz <- c("month", "year", "dan")
data_aggr_strani_ulaz$month_year_strani_ulaz <- do.call(paste, c(data_aggr_strani_ulaz[my_cols_strani_ulaz],
data_aggr_strani_ulaz <- data_aggr_strani_ulaz[ , ! colnames(data_aggr_strani_ulaz) %in% my_cols_strani_ulaz])

novi_datumi_strani_ulaz <- as.Date(data_aggr_strani_ulaz$month_year_strani_ulaz, format = "%m-%Y-%d")
data_aggr_strani_ulaz$month_year_strani_ulaz <- novi_datumi_strani_ulaz

ggplot(data_aggr_strani_ulaz, aes(x = month_year_strani_ulaz, y = vrijednosti)) +
  geom_line() +
  scale_x_date(date_labels = "%Y-%m") +
  scale_y_continuous(limits = c(0, 3300000))

```



Strani izlaz

```
library(ggplot2)
strani_izlaz_prometna_sredstva <- read.csv("strani_promet/strani_izlaz_prometna_sredstva.csv")

names(strani_izlaz_prometna_sredstva)

## [1] "X"                "osobni.automobili" "vlakovi"
## [4] "teretna.vozila"   "autobusi"          "plovila"
## [7] "zrakoplovi"      "UKUPNO"

attach(strani_izlaz_prometna_sredstva)

datum_i_strani_izlaz <- as.Date(strani_izlaz_prometna_sredstva$X, format = "%Y-%m-%d")

ukupno_strani_izlaz <- strani_izlaz_prometna_sredstva$UKUPNO
ukupno_strani_izlaz[ukupno_strani_izlaz > 170000] <- 37000

data_strani_izlaz <- data.frame(datum_i = datum_i_strani_izlaz, vrijednosti = ukupno_strani_izlaz)
data_strani_izlaz <- data_strani_izlaz[order(data_strani_izlaz$datum_i), ]


data_strani_izlaz_new <- data_strani_izlaz
data_strani_izlaz_new$year <- strftime(data_strani_izlaz_new$datum_i, "%Y")
data_strani_izlaz_new$month <- strftime(data_strani_izlaz_new$datum_i, "%m")
data_strani_izlaz_new$dan <- c("01")

data_aggr_strani_izlaz <- aggregate(vrijednosti ~ month + year + dan, data_strani_izlaz_new, FUN = sum)

my_cols_strani_izlaz <- c("month", "year", "dan")
data_aggr_strani_izlaz$month_year_strani_izlaz <- do.call(paste, c(data_aggr_strani_izlaz[my_cols_strani_izlaz],
  data_aggr_strani_izlaz <- data_aggr_strani_izlaz[, ! colnames(data_aggr_strani_izlaz) %in% my_cols_strani_izlaz])

novi_datumi_strani_izlaz <- as.Date(data_aggr_strani_izlaz$month_year_strani_izlaz, format = "%m-%Y-%d")
data_aggr_strani_izlaz$month_year_strani_izlaz <- novi_datumi_strani_izlaz

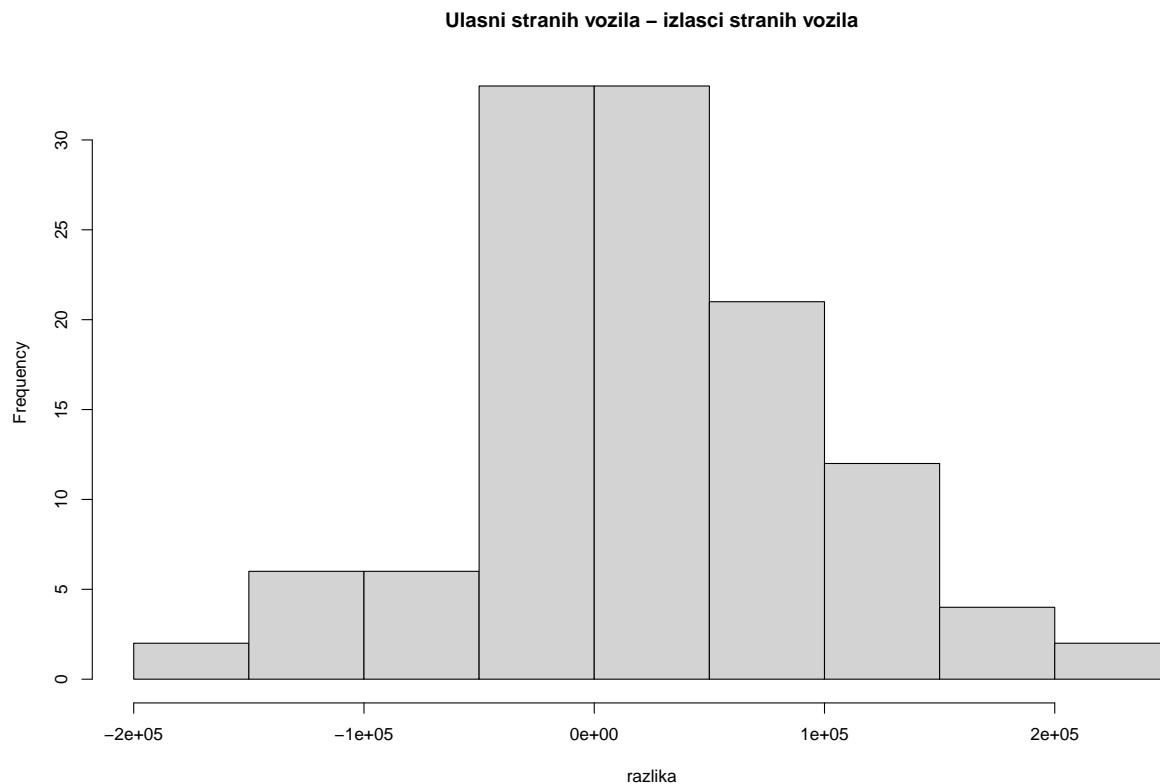
ggplot(data_aggr_strani_izlaz, aes(x = month_year_strani_izlaz, y = vrijednosti)) +
  geom_line() +
  scale_x_date(date_labels = "%Y-%m") +
  scale_y_continuous(limits = c(0, 3300000))
```



Strani razlika

```
razlika2<- data_aggr_strani_ulaz["vrijednosti"] - data_aggr_strani_izlaz["vrijednosti"]
strani_razlika <- data.frame(datumi=data_aggr_strani_izlaz$month_year_strani_izlaz, razlika=razlika2)

hist(strani_razlika$vrijednosti, main = "Ulasni stranih vozila - izlasci stranih vozila", xlab = "razlika")
```



Strani auti ulaz

```

auti<-strani_ulaz_prometna_sredstva$sobni.automobili

data_auti <- data.frame(datumi = datumi_strani_ulaz, vrijednosti = auti)
data_auti <- data_auti[order(data_auti$datumi), ]

data_new_auti <- data_auti
data_new_auti$year <- strftime(data_new_auti$datumi, "%Y")
data_new_auti$month <- strftime(data_new_auti$datumi, "%m")
data_new_auti$dan <- c("01")

data_aggr_auti_godina <- aggregate(vrijednosti ~ year, data_new_auti, FUN = sum)
auti_merge <- merge(x=data_new_auti, y=data_aggr_auti_godina, by.x=("year"), by.y=("year"))
data_aggr_auti <- aggregate(vrijednosti.x ~ month + year + dan + vrijednosti.y, auti_merge, FUN = sum)

my_cols_auti <- c("month", "year", "dan")
data_aggr_auti$month_year <- do.call(paste, c(data_aggr_auti[my_cols_auti], sep="-"))
data_aggr_auti <- data_aggr_auti[ , ! colnames(data_aggr_auti) %in% my_cols_auti]

novi_datumi_auti <- as.Date(data_aggr_auti$month_year, format = "%m-%Y-%d")
data_aggr_auti$month_year <- novi_datumi_auti

auti_x1<-data_aggr_auti$vrijednosti.x
auti_x2<-data_aggr_auti$vrijednosti.y
auti_df1<-data.frame(auti_x1, auti_x2)

```

```
auti_x3<-auti_df1/auti_df1[,2]
data_aggr_auti$vrijednosti.x <- auti_x3$auti_x1
```

Gledamo sezonalost prometnih sredstava. Ovdje je primjer za automobile, ali tako je napravljeno za sva sredstva. Izračunali smo koliko je automobila ušlo u jednoj godini i u jednom mjesecu i dijeili mjesečni broj ulazaka s pridruženim godišnjim brojem ulazaka i tako dobili mjesečni udio ulazaka za svako prometno sredstvo.

Strani ulaz vlakovi


Strani ulaz teretna vozila

Strani ulaz u autobusi

Strani ulaz plovila

Strani ulaz zrakoplovi

Graf za sezonalnost stranog ulaza



Graf pokazuje određenu sezonalnost za sva prometna sredstva. Za vlakove i teretna vozila sezonalnost je mnogo slabija, što je i logično s obzirom na prirodu tih sredstava.

```
data_aggr_auti_2018_2019 <- data_aggr_auti %>% filter(year(month_year) == 2018 | year(month_year) == 2019)
```

```
data_aggr_vlakovi_2018_2019 <- data_aggr_vlakovi %>% filter(year(month_year) == 2018 | year(month_year) == 2019)
```

```
data_aggr_teretna_vozila_2018_2019 <- data_aggr_teretna_vozila %>% filter(year(month_year) == 2018 | year(month_year) == 2019)
```


```
data_aggr_autobusi_2018_2019 <- data_aggr_autobusi %>% filter(year(month_year) == 2018 | year(month_year) == 2021)
data_aggr_plovila_2018_2019 <- data_aggr_plovila %>% filter(year(month_year) == 2018 | year(month_year) == 2021)
data_aggr_zrakoplovi_2018_2019 <- data_aggr_zrakoplovi %>% filter(year(month_year) == 2018 | year(month_year) == 2021)
```

Filtriranje podataka za sva prometna sredstva u preiodu 2018. - 2021.

Graf za 2018-2021

```
df_merged <- data.frame(
  datumi = data_aggr_auti_2018_2019$month_year,
  auti = data_aggr_auti_2018_2019$vrijednosti.x,
  vlakovi = data_aggr_vlakovi_2018_2019$vrijednosti.x,
  teretna_vozila = data_aggr_teretna_vozila_2018_2019$vrijednosti.x,
  autobusi = data_aggr_autobusi_2018_2019$vrijednosti.x,
  plovila = data_aggr_plovila_2018_2019$vrijednosti.x,
  zrakoplovi = data_aggr_zrakoplovi_2018_2019$vrijednosti.x
)

ggplot(data = df_merged, aes(x = datumi)) +
  geom_line(aes(y = auti, group = 1, color = "Auti")) +
  geom_line(aes(y = vlakovi, group = 2, color = "Vlakovi")) +
  geom_line(aes(y = teretna_vozila, group = 3, color = "Teretna vozila")) +
  geom_line(aes(y = autobusi, group = 4, color = "Autobusi")) +
  geom_line(aes(y = plovila, group = 5, color = "Plovila")) +
  geom_line(aes(y = zrakoplovi, group = 6, color = "Zrakoplovi")) +
  labs(x = "Vrijeme", y = "Postotak")
```



Graf također prikazuje udio pojedinog sredstva za određeni mjesec u određenoj godini, ali samo u preiodu 2018. - 2021. Jasno se vidi pojačanost svih oblika prometa u ljetnim mjesecima sve do pandemijske 2020. godine kada se linije razdvajaju, ali već pri kraju 2021. se vidi lagano ponovno spajanje linija.

Dolasci stranih vozila

```
dani_dolazaka <- data.frame(datumi = datumi_strani_ulaz, vrijednosti = ukupno_strani_ulaz, godina = for

dani_dolazaka$dan <- seq.int(nrow(dani_dolazaka))
dani_dolazaka$dan <- dani_dolazaka$dan%7

dan_u_godini <- dani_dolazaka %>% group_by( godina, dan) %>%
  summarise(sum_vrijednost=sum(vrijednosti),
            .groups = 'drop') %>%
  as.data.frame()

df_dan_u_godini <- data.frame(matrix(ncol=7, nrow=10))
rownames(df_dan_u_godini) <- c("2013","2014","2015","2016","2017","2018","2019","2020","2021","2022")


for(i in rownames(dan_u_godini)){
  if(is.na(df_dan_u_godini[dan_u_godini[i,"godina"], dan_u_godini[i,"dan"] + 1])){
    df_dan_u_godini[dan_u_godini[i,"godina"], dan_u_godini[i,"dan"] + 1] <- dan_u_godini[i,"sum_vrijednost"]
  } else{
    df_dan_u_godini[dan_u_godini[i,"godina"], dan_u_godini[i,"dan"] + 1] <- df_dan_u_godini[dan_u_godini[i,"godina"], dan_u_godini[i,"dan"] + 1] + dan_u_godini[i,"sum_vrijednost"]
  }
}
```



```
df_dan_u_godini
```

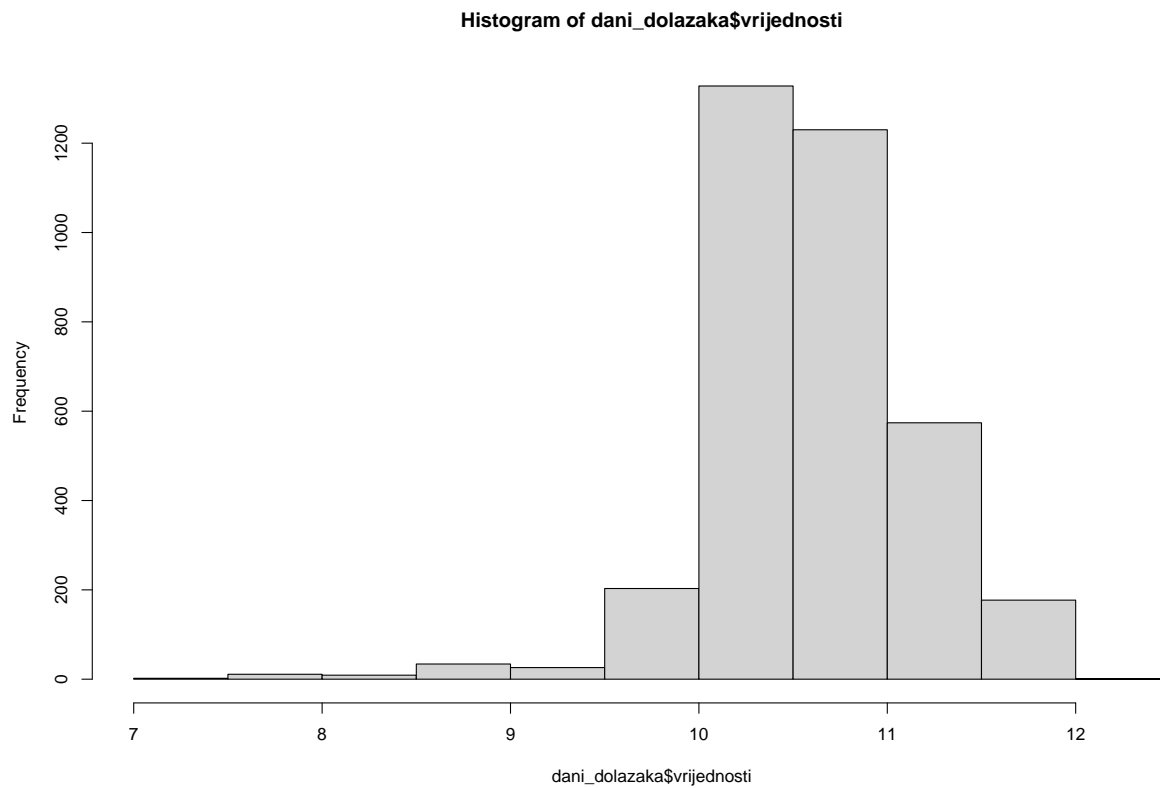
##		X1	X2	X3	X4	X5	X6	X7
##	2013	1886517	1748681	1819534	1999148	2504264	2829816	2302159
##	2014	1976906	1807729	1921651	2100004	2647413	2882577	2399490
##	2015	2174186	1971018	2100858	2286421	2837759	3040279	2547814
##	2016	2325168	2080193	2190512	2414710	3091976	3226161	2639007
##	2017	2442494	2203897	2297847	2502707	3168088	3290372	2774629
##	2018	2540942	2225273	2349350	2555258	3204434	3311163	2864380
##	2019	2643292	2385367	2470109	2707601	3412139	3396373	2966358
##	2020	1350057	1228484	1335824	1426319	1691061	1525280	1385095
##	2021	1921474	1711829	1792046	1984812	2436866	2291860	2070700
##	2022	2289465	1934359	1985435	2247059	2870404	2844182	2608857

```
hist(dani_dolazaka$vrijednosti)
```




```
dani_dolazaka$vrijednosti <- log(dani_dolazaka$vrijednosti)
```

```
hist(dani_dolazaka$vrijednosti)
```



```
qqnorm(dani_dolazaka$vrijednosti)
qqline(dani_dolazaka$vrijednosti)
```



```
require(nortest)
lillie.test(dani_dolazaka$vrijednosti)
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  dani_dolazaka$vrijednosti
## D = 0.074987, p-value < 2.2e-16
```

```
aov_result <- aov(dani_dolazaka$vrijednosti ~ dani_dolazaka$godina * dani_dolazaka$dan)
summary(aov_result)
```

```
##
##               Df Sum Sq Mean Sq F value Pr(>F)
## dani_dolazaka$godina      9   211.9    23.546  101.397 <2e-16 ***
## dani_dolazaka$dan         1    24.6    24.550  105.721 <2e-16 ***
## dani_dolazaka$godina:dani_dolazaka$dan      9     4.8     0.536   2.309 0.0139 *
## Residuals                3575   830.2     0.232
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Nakon logaritamske pretvorbe podataka dobivamo distribuciju sličniju normalnoj, ali funkcija `lillie.test()` pokazuje da i dalje nije normalna distribucija.

```
dani_dolazaka_filtered <- subset(dani_dolazaka, !(godina %in% c("2020", "2021", "2022")))
```

```
aov_result_filtered <- aov(dani_dolazaka_filtered$vrijednosti ~ dani_dolazaka_filtered$godina * dani_dolazaka_filtered$dan)
summary(aov_result_filtered)
```

```
##
##               Df Sum Sq Mean Sq
```

```
## dani_dolazaka_filtered$godina          6    28.0    4.673
## dani_dolazaka_filtered$dan             1    25.6   25.602
## dani_dolazaka_filtered$godina:dani_dolazaka_filtered$dan    6     0.1    0.024
## Residuals                           2542  435.0    0.171
##                                     F value Pr(>F)
## dani_dolazaka_filtered$godina          27.309 <2e-16 ***
## dani_dolazaka_filtered$dan            149.617 <2e-16 ***
## dani_dolazaka_filtered$godina:dani_dolazaka_filtered$dan    0.139  0.991
## Residuals
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Ako iz podataka o dolascima po danima izuzmemo pandemijske godine(2020.+), zbog velike p-vrijednosti zaključujemo da dan igra ulogu u broju dolazaka stranih prometnih sredstava, ali isto tako i godina. Kombinacija dana i godine je statistički beznačajna.

2.Pitanje:

Analizirajte fundamentalne podatke turističkih tvrtki – postoje li sezonalnosti i u njima?

Pregled turističkog sektora

Analizirana su kvartalna financijska izvješća (Q1, Q2, Q3 i Q4) u razdoblju od 2013. do 2022.

Učitat ćemo podatke za 4 turistička poduzeća; Maistru, Arenu, Valamar te Imperial.

```
maistra = select(read.csv("fundamenti/MAIS_fundamenti.csv"), -c("Published"))
arena = select(read.csv("fundamenti/ARNT_fundamenti.csv"), -c("Published"))
valamar = select(read.csv("fundamenti/RIVP_fundamenti.csv"), -c("Published"))
imperial = select(read.csv("fundamenti/HIMR_fundamenti.csv"), -c("Published"))
```

Financijsko izvješća za kompaniju Valamar nije dostupnoga treći kvartal 2013. godine.


Također, za sve kompanije nedostaju financijska izvješća za četvrti kvartal 2022. jer u vrijeme pisanja ovog rada izvješća još uvijek nisu bila objavljena.

Važno je istaknuti da u četvrtom kvartalu 2020. kompanija Imperial ima negativan prihod što može biti korektivna stavka zbog konsolidacije financijskih izvještaja unutar grupe.

S obzirom na to kako je najznačajniji dolazak turista svake godine u trećem kvartalu, a broj noćenja izravno povezan s prihodima, tada očekujemo da u tom kvartalu se isto tako najviše prometa generira. Stoga, napraviti ćemo ukupan pregled prometa za sva 4 poduzeća.

Prihodi turističkog sektora zadnjih 10 godina

```
totalRevenue <- rbind(maistra, valamar, arena, imperial)
totalRevenue <- aggregate(totalRevenue$Sales, by = list(totalRevenue$Quarter, totalRevenue$Year), FUN =
colnames(totalRevenue) <- c("Quarter", "Year", "Sales")
totalRevenue$Quarter = factor(totalRevenue$Quarter, levels = c(1,2,3,4), labels = c("Q1", "Q2", "Q3", "Q4"))
```



Iz grafa se može vidjeti da je najveći udio prihoda u svakoj pojedinačnoj godini ostvaren upravo u Q3. Kako bismo tu hipotezu s velikom pouzdanošću mogli potvrditi provest ćemo analizu varijance u kojoj ćemo vidjeti je li udio prihoda koji nastaje u Q3 statistički značajan.

Grafički možemo vidjeti kako su prihodi 2020. značajno pali u odnosu na ostale godine. Razlog tome je epidemija virusa COVID-19 koja je značajno pogodila Hrvatsku, a samim time i ulazak turista te posljedično prihode poduzeća. U kasnijim analizama fundamenata ćemo ovo smatrati outlierom jer je to realizacija sistemskog rizika na tržištu i izvan kontrole je na poslovanje poduzeća. (Uz to imamo veliku odstupanja od pretpostavki modela kad uključujemo 2020. godinu)

ANOVA

U svrhu analize za razdoblje 2013.-2022. zbrojeni su prihodi po kvartalima tako da se za svaku kompaniju utvrdio prihod svih prvih kvartala, svih drugih kvartala, svih trećih kvartala i svih četvrtih kvartala. Ti kvartalni prihodi su se zatim utvrdili za sve kompanije.


Tako su dobivene 4 kategorijske varijable/grupe (kvartali) od kojih svaka ima po 10 podataka, čime test postaje robusniji na pretpostavke.

Prije provedbe statističkog testa, moramo ispitati zadovoljavaju li podaci pretpostavke koje ANOVA zahtjeva.

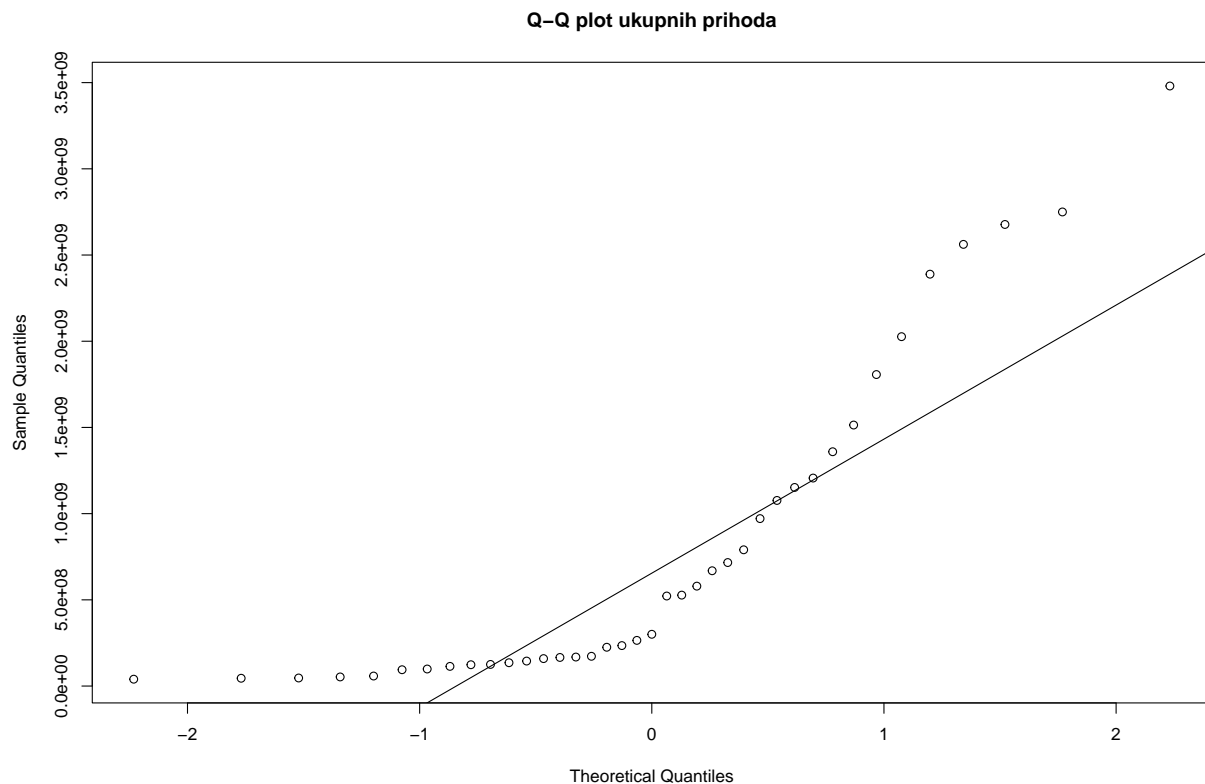
Nezavisnost pojedinih podataka u uzorcima: smatramo zadovoljenim upravo zato što prihodi koji su nastali u zasebnom kvartalu (npr. Q1) ne utječu na prihod iz bilo kojeg drugog kvartala.

Provjera normalne razdiobe podataka po grupama:

Histogram ukupnih prihoda



```
##  
##  Lilliefors (Kolmogorov-Smirnov) normality test  
##  
## data:  totalRevenue$Sales  
## D = 0.22033, p-value = 5.119e-05
```



```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  totalRevenue$Sales[totalRevenue$Quarter == "Q1"]
## D = 0.21237, p-value = 0.2267

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  totalRevenue$Sales[totalRevenue$Quarter == "Q2"]
## D = 0.16542, p-value = 0.6116

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  totalRevenue$Sales[totalRevenue$Quarter == "Q3"]
## D = 0.13143, p-value = 0.8943

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  totalRevenue$Sales[totalRevenue$Quarter == "Q4"]
## D = 0.16979, p-value = 0.6399

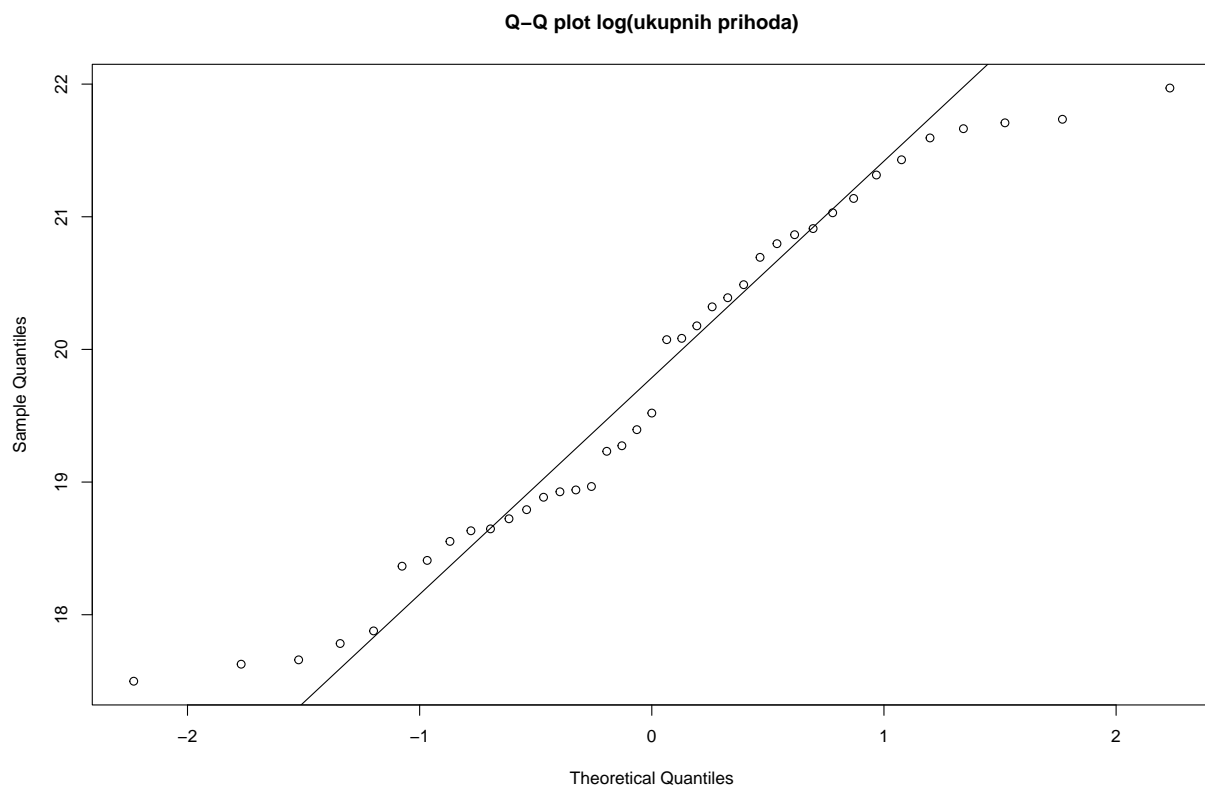
##
##  Bartlett test of homogeneity of variances
##
## data:  totalRevenue$Sales by totalRevenue$Quarter
## Bartlett's K-squared = 56.277, df = 3, p-value = 3.667e-12
```

Iz gore navedenih rezultata možemo primijetiti da prihodi po grupama tj. po kvartalima prate normalnu razdiobu, dok za grupirane prihode to ne vrijedi, što pokazuje Lilieforsov test i Q-Q plot. Također, napravili smo provjeru homogenosti varijance koristeći Bartlettov test koji nam je pokazao da su varijance grupa međusobno različite.

Histogram prihoda podsjeća na log-normalnu distribuciju. Kako bismo to i pokazali, primijenit ćemo log transformaciju da sve prihode svedemo na normalne i pritom samu varijancu grupa učinili homogenom. Time ćemo dobiti pouzdanije rezultate testa. Ako se distribucija prihoda ponaša po log-normalnoj distribuciji tj podaci se mogu opisati eksponencijalnom funkcijom, nakon transformacije bismo trebali dobiti normalne podatke.

```
transformed_data <- totalRevenue %>% mutate(Sales = log(Sales))

qqnorm(transformed_data$Sales, main = "Q-Q plot log(ukupnih prihoda)")
qqline(transformed_data$Sales)
```



```
lillie.test(transformed_data$Sales)

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  transformed_data$Sales
## D = 0.12858, p-value = 0.1069

lillie.test(transformed_data$Sales[totalRevenue$Quarter == "Q1"])

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
```



```
## data: transformed_data$Sales[totalRevenue$Quarter == "Q1"]
## D = 0.20751, p-value = 0.2569
lillie.test(transformed_data$Sales[totalRevenue$Quarter == "Q2"])


##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: transformed_data$Sales[totalRevenue$Quarter == "Q2"]
## D = 0.24632, p-value = 0.08668
lillie.test(transformed_data$Sales[totalRevenue$Quarter == "Q3"])

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: transformed_data$Sales[totalRevenue$Quarter == "Q3"]
## D = 0.17391, p-value = 0.5309
lillie.test(transformed_data$Sales[totalRevenue$Quarter == "Q4"])

##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: transformed_data$Sales[totalRevenue$Quarter == "Q4"]
## D = 0.18531, p-value = 0.4992
bartlett.test(transformed_data$Sales~totalRevenue$Quarter)

##
## Bartlett test of homogeneity of variances
##
## data: transformed_data$Sales by totalRevenue$Quarter
## Bartlett's K-squared = 1.1104, df = 3, p-value = 0.7746
```

Sada su sve pretpostavke ANOVA modela zadovoljene (nezavisnost, normalnost i homogenost) te možemo ići provesti statističko testiranje:



```
##               Df Sum Sq Mean Sq F value    Pr(>F)
## transformed_data$Quarter  3  57.72   19.240    59.04 8.96e-14 ***
## Residuals                35   11.41    0.326
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Iz boxplota vidimo da medijan prihoda u Q3 nadilazi sve granice outliera za ostale kvartale. Koristeći ANOVU smo pokazali da je razlika između prosječnih prihoda po kvartalima statistički značajna te da najviše prihoda turistička poduzeća ostvaruju u trećem kvartalu, što se jasno vidi iz boxplota.

Analiza fundamenata turističkih poduzeća

S obzirom na to da je neto marža jedan od ključnih fundamentalnih pokazatelja poslovanja poduzeća, taj pokazatelj je korišten u ovoj analizi. Neto marža izračunava se kao omjer neto dobiti i prihoda poduzeća.

Ona pokazuje koja od 4 različitih poduzeća ima najprofitabilniji poslovni model odnosno kako pojedina firma posluje. Neto marža je ovdje najbolji pokazatelj jer sva 4 poduzeća posluju u istom segmentu (turizam) čime nam analiza postaje puno preciznija zbog toga što imamo usporedive tvrtke.

Kako bismo vidjeli koje poduzeće je najprofitabilnije na godišnjoj razini opet ćemo provest analizu varijance.

```
maistra$Poduzece <- 1
valamar$Poduzece <- 2
arena$Poduzece <- 3
imperial$Poduzece <- 4


totalMargin <- rbind(maistra, valamar, arena, imperial)

totalMarginR <- aggregate(totalMargin$Sales, by = list(totalMargin$Year, totalMargin$Poduzece), FUN = sum)
```

```
totalMarginE <- aggregate(totalMargin$Earnings, by = list(totalMargin$Year, totalMargin$Poduzece), FUN = sum)

totalMargin <- cbind(totalMarginR, totalMarginE)
totalMargin <- totalMargin[!duplicated(as.list(totalMargin))]
colnames(totalMargin) <- c("Year", "Poduzece", "Sales", "Earnings")
totalMargin$Margins <- totalMargin$Earnings/totalMargin$Sales


totalMargin$Poduzece <- factor(totalMargin$Poduzece, levels = c(1,2,3,4), labels = c("Maistra", "Valamar", "Arena", "Imperial"))
```



Iz box plot-a vidimo da svako poduzeće ima nekoliko outlier-a. Iz podataka se može vidjeti da svako poduzeće ima negativnu maržu u 2020. zbog COVID-19.

S obzirom na to da smo prije naveli kako je to jedna izuzetna godina, nju ćemo maknuti iz podataka. Nakon toga ostajemo s jednim outlierom za Valamar i Arenu. Pregledom godišnjih financijskih izvještaja smo vidjeli da se u oba slučaja radi o akvizicijama hotela i konsolidaciji izvještaja što je rezultiralo negativnim neto maržama. 2013. je Valamar preuzeo trgovačko društvo Dubrovnik - Babin Kuk d.d., a Arena je u lipnju 2016. značajno promijenilo pravno ustrojstvo i vlasničku strukturu kupovinom tri hrvatska društva – Arenaturist Hoteli d.o.o., Arenaturist Zlatne stijene te d.o.o., Arenaturist Turistička naselja d.o.o.

S obzirom na to kako su grupe imale niz jednokratnih ili izvanrednih troškova koje ne pripadaju uobičajenom poslovanju, njih također smatramo outlierom i izbacujemo iz podataka.



Provedimo sad postupak ANOVE:

```
lillie.test(totalMargin$Margins)
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  totalMargin$Margins
## D = 0.13614, p-value = 0.1133
```

```
lillie.test(totalMargin$Margins[totalMargin$Poduzece == "Maistra"])
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  totalMargin$Margins[totalMargin$Poduzece == "Maistra"]
## D = 0.36933, p-value = 0.0008408
```

```
lillie.test(totalMargin$Margins[totalMargin$Poduzece == "Valamar"])
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  totalMargin$Margins[totalMargin$Poduzece == "Valamar"]
## D = 0.1661, p-value = 0.7428
```

```
lillie.test(totalMargin$Margins[totalMargin$Poduzece == "Arena"])
```


```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
```

```
##
## data: totalMargin$Margins[totalMargin$Poduzece == "Arena"]
## D = 0.14732, p-value = 0.8763
lillie.test(totalMargin$Margins[totalMargin$Poduzece == "Imperial"])
```

```
##
## Lilliefors (Kolmogorov-Smirnov) normality test
##
## data: totalMargin$Margins[totalMargin$Poduzece == "Imperial"]
## D = 0.23518, p-value = 0.1611
```

Provjerimo zašto Maistra ne prati normalnu distribuciju:

```
qqnorm(totalMargin$Margins[totalMargin$Poduzece == "Maistra"], main = "Q-Q plot Maistre")
qqline(totalMargin$Margins[totalMargin$Poduzece == "Maistra"])
```



Možemo vidjeti da jedino Maistra ne prati normalnost podatka zbog svoja 2 outliera odnosno dobrih neto marži.

```
bartlett.test(totalMargin$Margins~totalMargin$Poduzece)

##
## Bartlett test of homogeneity of variances
##
## data: totalMargin$Margins by totalMargin$Poduzece
## Bartlett's K-squared = 1.0349, df = 3, p-value = 0.7928
a = aov(totalMargin$Margins~totalMargin$Poduzece)
summary(a)
```

```
##               Df Sum Sq Mean Sq F value Pr(>F)
## totalMargin$Poduzece  3 0.02231 0.007436   1.775   0.173
## Residuals          30 0.12566 0.004189
```

Ostali svi podaci zadovoljavaju pretpostavke ANOVE te korištenjem statističkog testa, u kojem je p vrijednost 0.17 možemo s velikom pouzdanošću tvrditi da na godišnjoj razini ne postoji statistički značajna razlika između poslovanja naših 4 turističkih poduzeća, odnosno svi su podjednako profitabilni.

Valuacije poduzeća

Pored neto marži, P/E (price to earnings) jedan je od fundamentalnih omjera koji uspoređuje cijenu dionice poduzeća s njegovom zaradom po dionici (EPS) i koristi se za određivanje vrijednosti. Viši P/E omjer općenito ukazuje na to da je dionica skuplja i da investitori imaju veća očekivanja za budući rast zarade tvrtke.


Na ZSE ćemo pogledati broj dionica i pretpostaviti ćemo da se unazad 10 godina nisu mijenjale u korist naše analize. Izračunat ćemo EPS za svaku dionicu te iz toga dobiti P/E.

```
totalMargin$NS[totalMargin$Poduzece == "Maistra"] <- 10944339
totalMargin$NS[totalMargin$Poduzece == "Valamar"] <- 126027542
totalMargin$NS[totalMargin$Poduzece == "Arena"] <- 5128721
totalMargin$NS[totalMargin$Poduzece == "Imperial"] <- 2279473

totalMargin$EPS[totalMargin$Poduzece == "Maistra"] <- totalMargin$Earnings[totalMargin$Poduzece == "Maistra"] / totalMargin$NS[totalMargin$Poduzece == "Maistra"]
totalMargin$EPS[totalMargin$Poduzece == "Valamar"] <- totalMargin$Earnings[totalMargin$Poduzece == "Valamar"] / totalMargin$NS[totalMargin$Poduzece == "Valamar"]
totalMargin$EPS[totalMargin$Poduzece == "Arena"] <- totalMargin$Earnings[totalMargin$Poduzece == "Arena"] / totalMargin$NS[totalMargin$Poduzece == "Arena"]
totalMargin$EPS[totalMargin$Poduzece == "Imperial"] <- totalMargin$Earnings[totalMargin$Poduzece == "Imperial"] / totalMargin$NS[totalMargin$Poduzece == "Imperial"]
```

Učitati ćemo CSV s cijenama dionica u kojima ćemo pronaći cijene dionica na zadnji dan trgovanja za svaku godinu kako bi se cijena poklapala s dobiti na kraju godine.

Analizirajući podatke smo utvrdili značajno velike outliere PE omjera (1200 za Arenu) koje smo izbacili kao i sve negativne vrijednosti jer one iz perspektive investiranja/valuacije te usporedbe nemaju smisla. Pogledajmo PE




omjere turističkih poduzeća:

Boxplot sugerira da je Imperial precijenjen. 50% njegovih PE omjera za nalazi iznad gornjeg kvartila svih poduzeća i granice outliera. Razliku između prosječnih PE omjera provjeravamo ANOVA testom, no prije toga idemo pregledati podatke:

```
hist(total$PE, main = "Histogram PE omjera turističkih poduzeća")
```

Histogram PE omjera turističkih poduzeca

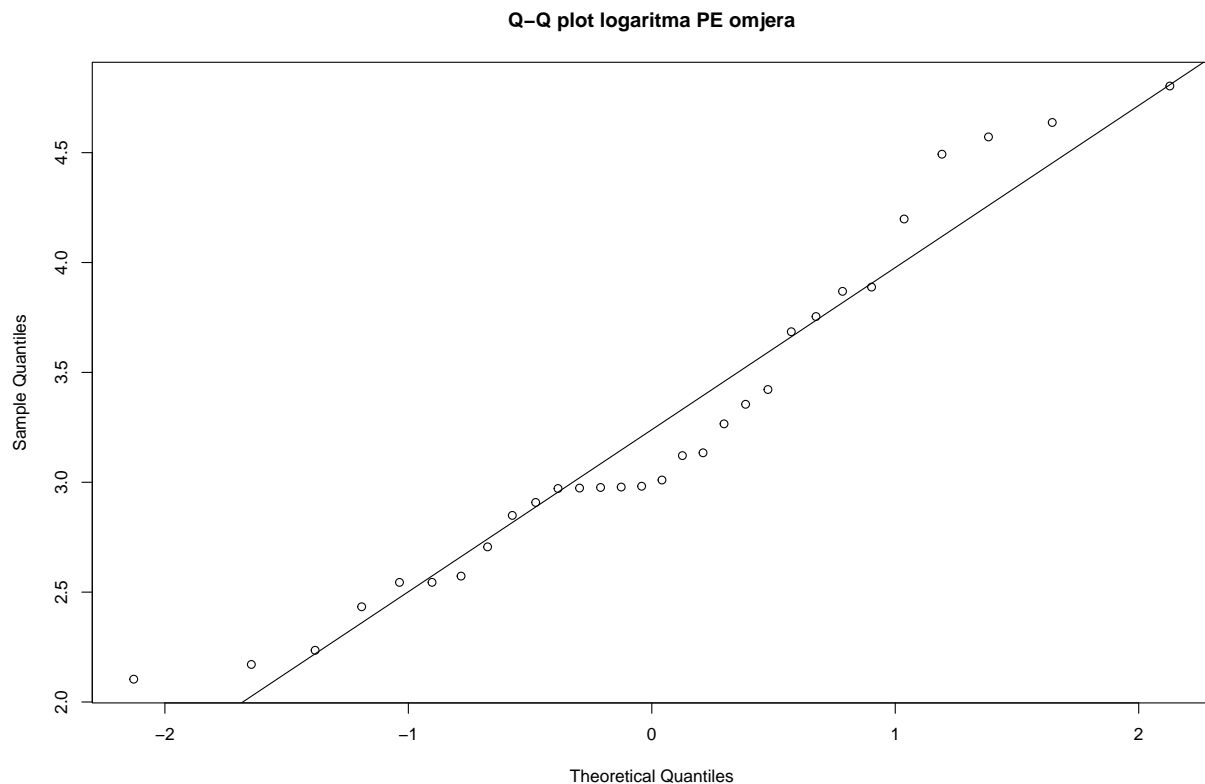


Probat ćemo nad ovim podacima također primjeniti logaritamsku transformaciju i ukoliko se podaci ponašaju normalnu nastaviti ćemo dalje s testom.

```
transformed_dataPE <- total %>% mutate(PE = log(PE))
```

Pogledajmo Q-Q plot logaritamskih podataka:

```
qqnorm(transformed_dataPE$PE, main = "Q-Q plot logaritma PE omjera")
qqline(transformed_dataPE$PE)
```

Provest ćemo test normalnosti:

```
lillie.test(transformed_dataPE$PE)
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  transformed_dataPE$PE
## D = 0.15518, p-value = 0.06318
```

P vrijednost je veća od 0.05, što znači da na razini značajnosti od 5% možemo tvrditi da su podaci normalni. Sad treba provjeriti isto po grupama:

```
lillie.test(transformed_dataPE$PE[transformed_dataPE$Poduzece == "Maistra"])
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  transformed_dataPE$PE[transformed_dataPE$Poduzece == "Maistra"]
## D = 0.28528, p-value = 0.03336
```

```
lillie.test(transformed_dataPE$PE[transformed_dataPE$Poduzece == "Valamar"])
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  transformed_dataPE$PE[transformed_dataPE$Poduzece == "Valamar"]
## D = 0.1108, p-value = 0.9945
```

```

lillie.test(transformed_dataPE$PE[transformed_dataPE$Poduzece == "Arena"])

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  transformed_dataPE$PE[transformed_dataPE$Poduzece == "Arena"]
## D = 0.15196, p-value = 0.9348

lillie.test(transformed_dataPE$PE[transformed_dataPE$Poduzece == "Imperial"])

##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  transformed_dataPE$PE[transformed_dataPE$Poduzece == "Imperial"]
## D = 0.20191, p-value = 0.5251

bartlett.test(transformed_dataPE$PE~transformed_dataPE$Poduzece)

##
##  Bartlett test of homogeneity of variances
##
## data:  transformed_dataPE$PE by transformed_dataPE$Poduzece
## Bartlett's K-squared = 5.2218, df = 3, p-value = 0.1563

a = aov(transformed_dataPE$PE~transformed_dataPE$Poduzece)
summary(a)

##
##              Df Sum Sq Mean Sq F value Pr(>F)
## transformed_dataPE$Poduzece  3  6.764    2.255    6.045 0.0029 **
## Residuals                26  9.699    0.373
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Ovaj slučaj je sličan kao prethodna dva. Omjeri se mogu ravnati po log-normalnoj razdiobi te se primjenom logaritamske transformacije PE omjeri poduzeća normaliziraju (osim Maistre), a varijance homogeniziraju (p vrijednost 0.156). ANOVOM smo pokazali da uz p vrijednost (0.0029) koja je manja od 1% postoji statistički značajna razlika između prosječnih PE omjera poduzeća.

PE omjeri Maistre, Valamara i Arene ne bi trebali biti toliko međusobno različiti (boxplot gore). Tu hipotezu bismo mogli dodatno provjeriti tako da izbacimo Imperial iz skupa i provedemo ANOVU za ta tri poduzeća.

Zaključak

Hrvatska turistička poduzeća ne ostvaruju prosječno istu količinu svojih prihoda u svim kvartalima. Većinu svojih prihoda ostvare u 3. kvartalu.

Pored toga, na godišnjoj razini ne postoji značajna razlika između njihovog poslovanja odnosno profitabilnosti.

Na kraju, promatrajući PE omjere, Imperial pokazuje znakove precijenjenosti u odnosu na ostala poduzeća u istom segmentu. Cijena dionice Maistre s druge strane može ukazivati na podcijenjenost; postoji mogućnost za potencijalni dugoročni rast s obzirom na to da tržište možda nije do kraja prepoznalo njenu pravu vrijednost analizirajući njenu najveću prosječnu neto maržu i najmanji prosječni PE omjer.

3.Pitanje:

Mogu li se fundamenti objasniti mobilnošću turista preko hrvatskih granica i u kojoj mjeri? Koja je vrsta prometa najznačajnija za hrvatska turistička poduzeća?

Kako bismo zaključili mogu li se fundamenti objasniti mobilnošću turista preko granica odlučili smo koristiti podatke prije 2019. godine. Naime 2019. nastupila je pandemija i promet preko granica znatno je stagnirao. Također smo se vodili pretpostavkom da su turisti skloniji odsjedanju u hotelima stoga smo gledali podatke stranog prometa.

Izbacivanje outliera iz pojedinih graničnih prijelaza smo obavili na način da se vrijednost postavlja na 0 kako ne bi pridonjeli sumi grupiranoj po godini i kvartalu te kako se ne bi morao izbrisati cijeli redak tog dana te izgubile vrijednosti ostalih prijelaza.

```
is_outlier <- function(x, iqrfac = 1.5) {
  quants <- quantile(x, na.rm = FALSE)
  iqr <- quants[4] - quants[2]
  (x < (quants[2] - iqrfac*iqr) | (quants[4] + iqrfac*iqr) < x)
}

data.ulaz.putnici.clean <- data.ulaz.putnici %>% mutate(across(-c(X), ~ifelse(is_outlier(.x), 0, .x)))
```

Na granične prijelaze dodajemo stupce godine i kvartala, grupiramo podatke po istima i vrijednosti zbrajamo po pojedinim graničnim prijelazima

```
data.ulaz.putnici.clean$YEAR <- with(data.ulaz.putnici.clean,
                                     year(as.POSIXlt(data.ulaz.putnici.clean$X,
                                                         format = "%Y-%m-%d")))

data.ulaz.putnici.clean$QUARTER <- with(data.ulaz.putnici.clean,
                                         ceiling((month(as.POSIXlt(data.ulaz.putnici.clean$X,
                                                                     format = "%Y-%m-%d")))/3))

summed.ulaz <- data.ulaz.putnici.clean[data.ulaz.putnici.clean$YEAR < 2019,2:9] %>%
  group_by(YEAR, QUARTER) %>%
  summarise_all(sum)
```

Svakom poduzeću dodajemo iznad izračunate podatke zbog jednostavnijeg korištenja

```
arnt.joined <- inner_join(data.fund.arnt, summed.ulaz, by=c('Year'='YEAR', 'Quarter'='QUARTER'))
arnt.joined <- arnt.joined[,-1]

himr.joined <- inner_join(data.fund.himr, summed.ulaz, by=c('Year'='YEAR', 'Quarter'='QUARTER'))
himr.joined <- himr.joined[,-1]

mais.joined <- inner_join(data.fund.mais, summed.ulaz, by=c('Year'='YEAR', 'Quarter'='QUARTER'))
mais.joined <- mais.joined[,-1]

rivp.joined <- inner_join(data.fund.rivp, summed.ulaz, by=c('Year'='YEAR', 'Quarter'='QUARTER'))
rivp.joined <- rivp.joined[,-1]
```

Prije bilo kakvih zaključaka o modelu regresije pogledat ćemo tablicu korelacija parova graničnih prijelaza.

```
cor(cbind(summed.ulaz[,3:7]))
```

```
##           Cestovni  Željeznički  Riječni  Pomorski  Zračni
## Cestovni    1.0000000    0.5538109  0.9540979  0.8909664  0.8624980
## Željeznički 0.5538109    1.0000000  0.5692678  0.5565261  0.5204270
## Riječni     0.9540979    0.5692678  1.0000000  0.9276796  0.9145656
## Pomorski    0.8909664    0.5565261  0.9276796  1.0000000  0.9502013
## Zračni      0.8624980    0.5204270  0.9145656  0.9502013  1.0000000
```

Gledajući u koeficijente korelacije primjećujemo da su svi veći od 0.5 te se da zaključiti kako su svi parovi

varijabli vrlo snažno korelirani. Iz tog zaključka ćemo se ograničiti na model s jednim graničnim prijelazom, no uvest ćemo i “Dummy” varijable kvartala kako bi smanjili utjecaj sezonalnosti. Ove varijable uspoređujemo sa prihodom (Sales) iz razloga što neto-dobit (Earnings) ovisi o samom poslovnom modelu poduzeća stoga je prihod bolji kandidat.

```
arnt.joined.d = dummy_cols(arnt.joined,select_columns='Quarter')
arnt.fits <- list()
for(i in names(arnt.joined)[5:10]){
  arnt.fits[[i]] <- lm(Sales~get(i)+Quarter_1+Quarter_2+Quarter_3, data=arnt.joined.d)
}

himr.joined.d = dummy_cols(himr.joined,select_columns='Quarter')
himr.fits <- list()
for(i in names(himr.joined)[5:10]){
  himr.fits[[i]] <- lm(Sales~get(i)+Quarter_1+Quarter_2+Quarter_3, data=himr.joined.d)
}

mais.joined.d = dummy_cols(mais.joined,select_columns='Quarter')
mais.fits <- list()
for(i in names(mais.joined)[5:10]){
  mais.fits[[i]] <- lm(Sales~get(i)+Quarter_1+Quarter_2+Quarter_3, data=mais.joined.d)
}

rivp.joined.d = dummy_cols(rivp.joined,select_columns='Quarter')
rivp.fits <- list()
for(i in names(rivp.joined)[5:10]){
  rivp.fits[[i]] <- lm(Sales~get(i)+Quarter_1+Quarter_2+Quarter_3, data=rivp.joined.d)
}
```


Kao primjer ćemo uzeti rezultate modela Maistre za zračni promet.

```
summary(mais.fits$Zračni)

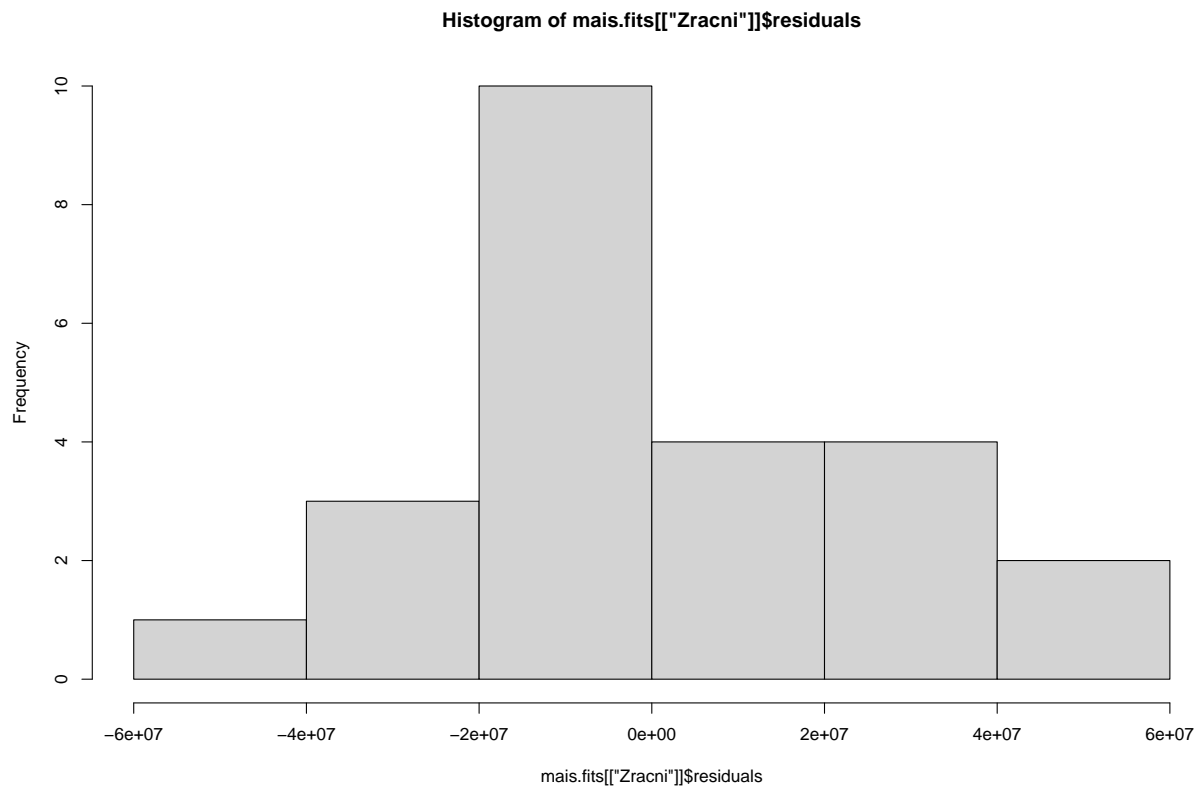
##
## Call:
## lm(formula = Sales ~ get(i) + Quarter_1 + Quarter_2 + Quarter_3,
##     data = mais.joined.d)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -57125600 -15354969  -2534270  18594172  49227343
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) -1.221e+08  2.409e+07  -5.069 6.81e-05 ***
## get(i)       6.479e+02  7.731e+01   8.381 8.34e-08 ***
## Quarter_1    6.762e+07  2.044e+07   3.309 0.00369 **
## Quarter_2   -1.670e+08  4.512e+07  -3.700 0.00152 **
## Quarter_3    -8.377e+07  7.967e+07  -1.051 0.30625
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 29850000 on 19 degrees of freedom
## Multiple R-squared:  0.9882, Adjusted R-squared:  0.9857
## F-statistic: 396.3 on 4 and 19 DF,  p-value: < 2.2e-16
```

Gledajući rezultate, model pokazuje vrlo visoku linearnu vezu zračnog prometa i prihoda što zaključujemo iz vrijednosti R^2 i Adjusted R^2 . Nadalje, gledamo normalnost residuala grafički i provodeći Lilliefors-test normalnosti.


```
plot(mais.fits[["Zračni"]]$residuals)
```




```
hist(mais.fits[["Zračni"]]$residuals)
```



```
hist(rstandard(mais.fits[["Zračni"]]))
```



```
qqnorm(rstandard(mais.fits[["Zračni"]]))  
qqline(rstandard(mais.fits[["Zračni"]]))
```



```
lillie.test(rstandard(mais.fits[["Zračni"]]))
```

```
##
##  Lilliefors (Kolmogorov-Smirnov) normality test
##
## data:  rstandard(mais.fits[["Zračni"]])
## D = 0.10693, p-value = 0.68
```

Grafička analiza nam može dati intuitivnu sliku o normalnosti residuala. U ovom slučaju Lillieforsov test ne odbacuje H_0 hipotezu o normalnosti. Provođenjem regresija svih poduzeća i graničnih prijelaza dobivamo sljedeće rezultate:

```
##Arena Hospitality Group d.d.
```

```
for(prijelaz in prijelazi){
  arnt <- arnt.fits[[prijelaz]]
  fstatistic <- summary(arnt)$fstatistic
  message(paste0(prijelaz, "\n",
    "R squared: ", summary(arnt)$r.squared, "\n",
    "Lilliefors-test p-value: ", lillie.test(rstandard(arnt))$p.value, "\n",
    "F-test p-value: ", pf(fstatistic["value"],
      fstatistic["numdf"],
      fstatistic["dendf"], lower.tail = FALSE)))
}
```

```
##Imperial Riviera d.d.
```

```
for(prijelaz in prijelazi){
  himr <- himr.fits[[prijelaz]]
  fstatistic <- summary(himr)$fstatistic
```



```

message(paste0(prijelaz, "\n",
               "R squared: ", summary(himr)$r.squared, "\n",
               "Lilliefors-test p-value: ", lillie.test(rstandard(himr))$p.value, "\n",
               "F-test p-value: ", pf(fstatistic["value"],
                                     fstatistic["numdf"],
                                     fstatistic["dendf"], lower.tail = FALSE)))
}

##Maistra d.d.
for(prijelaz in prijelazi){
  mais <- mais.fits[[prijelaz]]
  fstatistic <- summary(mais)$fstatistic
  message(paste0(prijelaz, "\n",
                 "R squared: ", summary(mais)$r.squared, "\n",
                 "Lilliefors-test p-value: ", lillie.test(rstandard(mais))$p.value, "\n",
                 "F-test p-value: ", pf(fstatistic["value"],
                                         fstatistic["numdf"],
                                         fstatistic["dendf"], lower.tail = FALSE)))
}

##Valamar Riviera d.d.
for(prijelaz in prijelazi){
  rvp <- rvp.fits[[prijelaz]]
  fstatistic <- summary(rvp)$fstatistic
  message(paste0(prijelaz, "\n",
                 "R squared: ", summary(rvp)$r.squared, "\n",
                 "Lilliefors-test p-value: ", lillie.test(rstandard(rvp))$p.value, "\n",
                 "F-test p-value: ", pf(fstatistic["value"],
                                         fstatistic["numdf"],
                                         fstatistic["dendf"], lower.tail = FALSE)))
}

```

Većina rezultata nam daje vrlo dobar linearni model stoga možemo zaključiti da postoji veza između fundemena i graničnih prijelaza. Za modele svih poduzeća najbolje rezultate nam daje model Zračnog prometa. U nekim modelima vidimo da je p-vrijednost Lillieforsovog testa normalnosti ispod 0.05 te u tim slučajevima odbacujemo H_0 hipotezu o normalnosti. No mi ćemo prihvatiti te modele oslanjajući se na otpornost linearne regresije i normalnosti podataka.